

Exposé Bachelorarbeit

Ben Tischberger

1 Problemstellung

Brettspielanleitungen werden für Menschen in natürlicher Sprache geschrieben. Durch diese Formulierungen können jedoch unklare Regeln entstehen, welche Spielraum für Interpretation lassen, Verhalten in Sonderfälle nicht eindeutig klären oder zu Fällen führen, die dann nicht weiter erklärt werden.

Für eine menschliche Spielergruppe ist das meistens kein großes Problem, da sie sich am Tisch einigen oder eigene Version ausdenken können. Für Computerprogramme funktioniert das nicht so einfach, da diese eindeutige Regeln brauchen. Sie müssen genau wissen, welche Züge erlaubt sind und wann ein Spiel endet um einen möglichen Gewinner zu bestimmen.

Daraus kann man folgendes Problem ableiten:

”Brettspielanleitungen können nicht immer in eine eindeutige Spielumgebung übersetzt werden”. Es stellt sich die Frage, ob Large Language Models (=LLMs) dabei helfen können, Anleitungen in ausführbare Spielumgebungen zu übersetzen und mögliche Unklarheiten sichtbar zu machen.

2 Lösungsidee

Eine Idee orientiert sich an PaperBench von OpenAi [1]. PaperBench ist ein Benchmark bei dem KI-Agenten wissenschaftliche Paper verstehen und die darin beschriebenen Experimente durch eigenen Code nachbauen sollen. Bewertet wird dabei wie gut der Agent den Inhalt verstanden und umgesetzt hat.

Dieser Ansatz könnte auf Brettspiele übertragen werden, wobei das LLM statt eines wissenschaftlichen Papers eine Brettspielanleitung bekommt. Aus dieser Anleitung soll das Modell eine ausführbare Spielumgebung erstellen, die anschließend getestet und bewertet werden kann.

Ein dafür wichtiger Teil der Arbeit wird es, ein Bewertungsschema zu entwickeln, welches dann genutzt werden kann um die Ausgabe des LLMs zu bewerten. Dazu gehören zum Beispiel die Vollständigkeit der erzeugten Dateien, die Ausführbarkeit des Codes, die Struktur eines möglichen Repositorys und die korrekte Umsetzung der Spielregeln.

Zur Überprüfung der Funktionalität kann OpenSpiel von Google DeepMind verwendet werden [2]. Die Open-Source-Bibliothek stellt verschiedene Spielumgebungen und Algorithmen für Reinforcement Learning bereit. Einige der dort bereits implementierten Spiele sollen anschließend als Referenz für den Vergleich genutzt werden, um zu überprüfen ob die erzeugten Spielumgebungen sich ähnlich verhalten. Dabei können zum Beispiel erlaubte Aktionen, Zustandsänderungen, Spielende und Gewinner verglichen werden.

Zusätzlich könnte ein Agent auf einer Umgebung trainiert und anschließend auf der anderen Umgebung getestet werden, damit soll geprüft werden, ob sich beide Umgebungen ähnlich verhalten oder ob deutliche Unterschiede bestehen.

Des weiteren kann dieser Versuchsaufbau mit verschiedensten LLMs von unterschiedlichen Anbietern für die unterschiedlichsten Spiele wiederholt werden, um zu überprüfen ob und wie diese Faktoren einen Unterschied auf das Ergebnis haben können.

3 Ziel

Das Ziel dieser Arbeit ist es zu untersuchen, ob Large Language Modelle ein sinnvoller Weg sind Brettspielanleitungen auf ihre Eindeutig- und Richtigkeit zu überprüfen, indem sie diese in eine ausführbare Spielumgebungen übersetzen.

Mit dem entwickelten Bewertungsschema können dann die verschiedenen LLM-Antworten überprüft, bewertet und möglicherweise optimiert werden.

Zusätzlich soll betrachtet werden, ob unterschiedliche LLMs oder unterschiedliche Spiele zu unterschiedlichen Ergebnissen führen. Besonders interessant ist dabei, ob bekannte Spiele wie Schach besser umgesetzt werden als weniger bekannte Spiele, da sie vermutlich stärker in den Trainingsdaten von LLMs vertreten sind. Dadurch soll besser eingeschätzt werden können, ob die Bekanntheit eines Spiels einen Einfluss auf die Qualität der erzeugten Spielumgebung hat.

References

- [1] Giulio Starace, Oliver Jaffe, Dane Sherburn, James Aung, Jun Shern Chan, Leon Maksin, Rachel Dias, Evan Mays, Benjamin Kinsella, Wyatt Thompson, Johannes Heidecke, Amelia Glaese, and Tejal Patwardhan. PaperBench: Evaluating AI’s ability to replicate AI research. In Aarti Singh, Maryam Fazel, Daniel Hsu, Simon Lacoste-Julien, Felix Berkenkamp, Tegan Maharaj, Kiri Wagstaff, and Jerry Zhu, editors, *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 56843–56873. PMLR, 13–19 Jul 2025.
- [2] Marc Lanctot, Edward Lockhart, Jean-Baptiste Lespiau, Vinicius Zambaldi, Satyaki Upadhyay, Julien Pérolat, Sriram Srinivasan, Finbarr Timbers, Karl Tuyls, Shayegan Omidshafiei, Daniel Hennes, Dustin Morrill, Paul Muller, Timo Ewalds, Ryan Faulkner, János Kramár, Bart De Vylder, Brennan Saeta, James Bradbury, David Ding, Sebastian Borgeaud, Matthew Lai, Julian Schrittwieser, Thomas Anthony, Edward Hughes, Ivo Danihelka, and Jonah Ryan-Davis. OpenSpiel: A framework for reinforcement learning in games. *CoRR*, abs/1908.09453, 2019.